



DS50 : Prédication tumeur cérébrale

*Osman Gaygusuz, Gaspard Rochu, Eléanore Renaud, Théo Gouin,
Elise Albrecht, Jérémie Kimenau*



Sommaire

01 Contexte

02 Traitement des données

03 Modèles utilisés

04 Conclusion

01 Contexte


- Les tumeurs cérébrales sont de tailles et localisations variées :
 - Rendent les diagnostics **complexe**
 - Nécessitent l'expertise de neurochirurgiens
- Système automatisé permet:
 - **Accélérer** et **fiabiliser** l'analyse des tumeurs
 - Palier un manque de spécialistes et de connaissances




02 Traitement des données

Le dataset


- Dataset de classification
- 3 tumeurs à identifier :
 - Gliome
 - Meningiome
 - Tumeur hypophysaire (*Pituitary*)
 - Pas de tumeur
- 2700 images d'entraînement
- 400 images de test




Meningiome



Pituitaire



Gliome



Pas de tumeur








02 Traitement des données




Les images

Images :

- Vue du dessus
- Vue de côté
- Vue de derrière...
- Différentes tailles
- Différentes proportions
- Différentes orientations



02 Traitement des données




Recadrage des images afin de n'avoir que la partie intéressante pour le modèle

02 Traitement des données



495x619




224x224 (DenseNet/ResNet)
240x240 (EfficientNet)

Redimensionnement des images pour les adapter aux entrées des modèles


02 Traitement des données

Dilatation des images:

- Objectif: Remplir les potentiels petits trous dans l'image
- Conséquences: Effet de grossissement des traits




Source: <https://www.mathworks.com/>



Source: <https://www.mathworks.com/>

Erosion des images:

- Objectif: Supprimer les potentiels pixels flottants
- Conséquences: Effet d'amincissement des traits




03

Modèles utilisés

03 Modèles utilisés

Densenet



- Architecture utilisant des couches denses → **concaténation par canal**


- Permet de **réduire considérablement le nombre de paramètres** à déterminer → entraînement plus rapide

3 entraînement différents:


- modèle implémenté à la main
- modèle implémenté par Keras
- entraînement avec FastAI

03 Modèles utilisés

Resultats



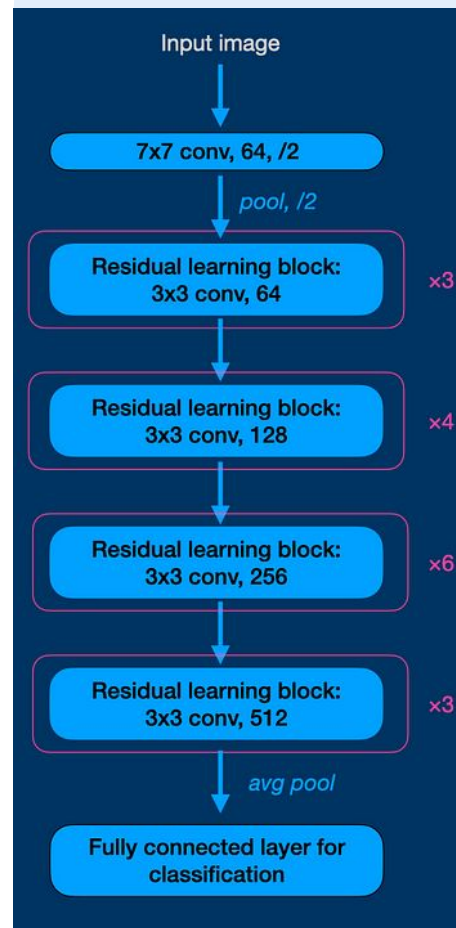
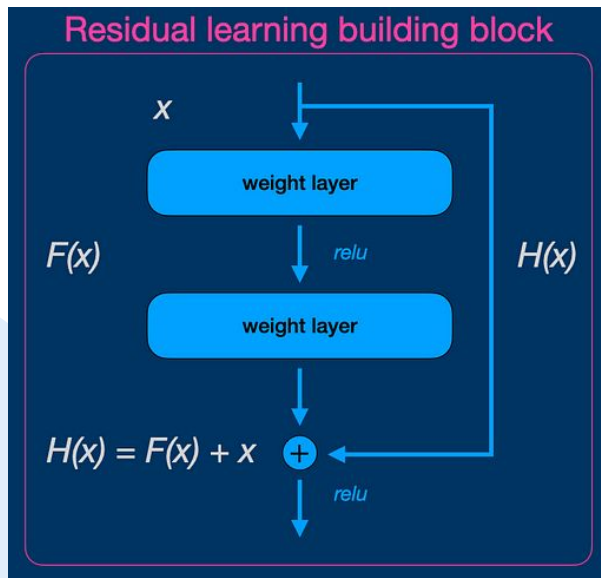
Modèle implémenté à la main



Modèle optimisé par FastAI

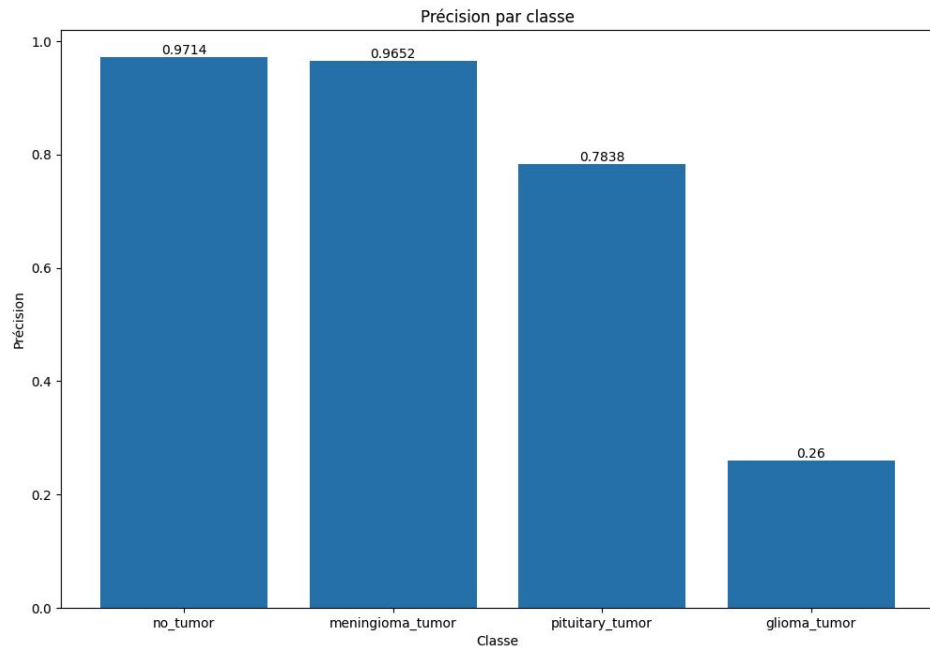
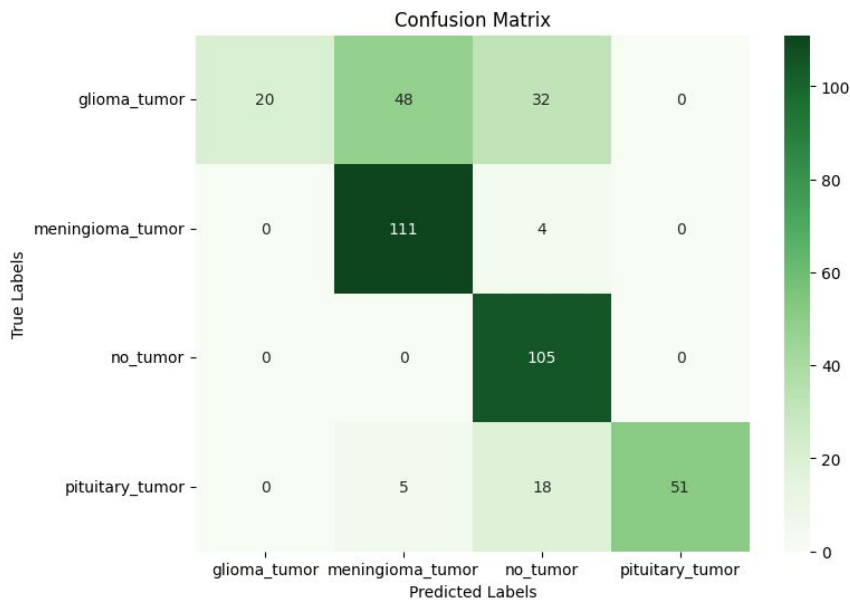
03 Modèles utilisés

ResNet



03 Modèles utilisés

ResNet

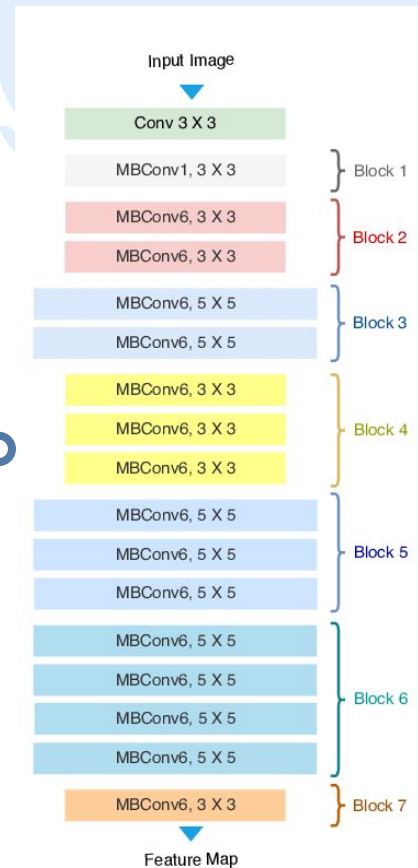


03 Modèles utilisés :

EfficientNetB1

Architecture CNN
développé par Google AI :
B0 à B7

Compound scaling : optimise
les performances en équilibrant
profondeur, la largeur et la
résolution

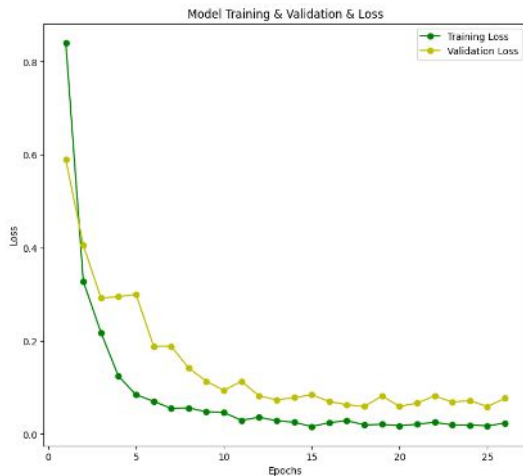
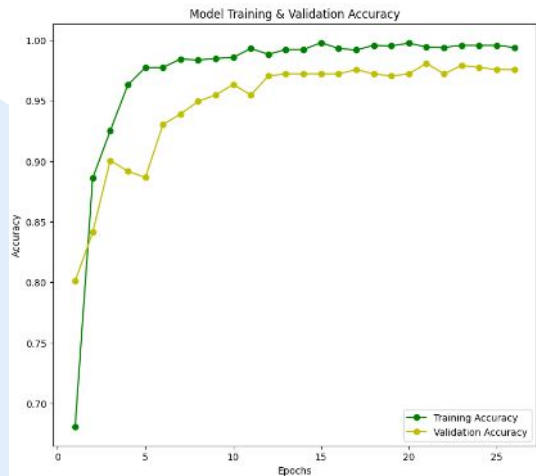


03 Modèles utilisés : EfficientNetB1



Accuracy pour le training set : 1.0

Accuracy pour le test set : 0.81



Confusion Matrix

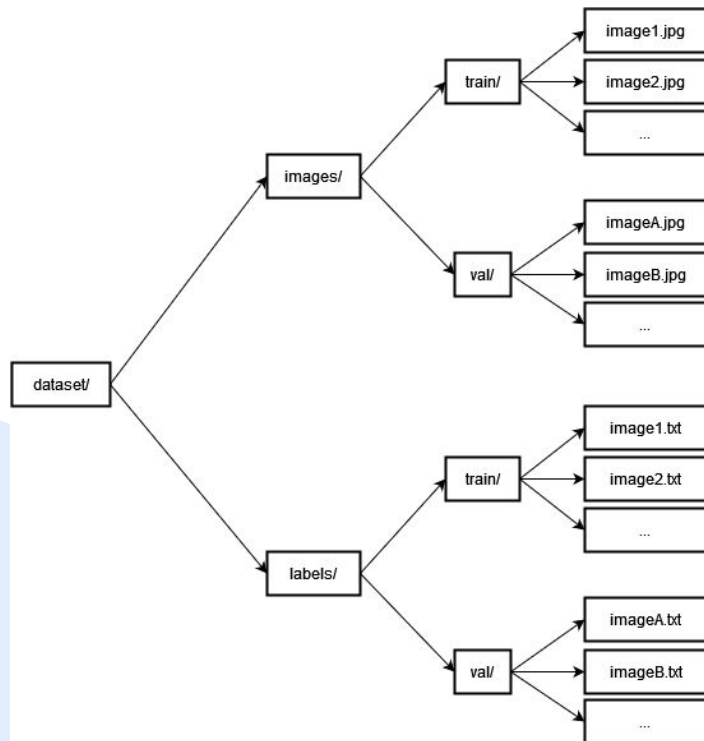
	no_tumor	pituitary_tumor	meningioma_tumor	glioma_tumor
no_tumor	35	47	18	0
pituitary_tumor	0	115	0	0
meningioma_tumor	1	0	104	0
glioma_tumor	0	5	13	56

True label

Predicted label

03 Modèles utilisés

YOLO



Mise en forme du dataset




```
zidane.txt ~
0 0.481719 0.634028 0.690625 0.713278
0 0.741094 0.524306 0.314750 0.933389
27 0.364844 0.795833 0.078125 0.400000
```


03 Modèles utilisés

YOLO

Résultats des tests



Précision : 77,48%

Recall : 73,75%

Accuracy : 74,1%

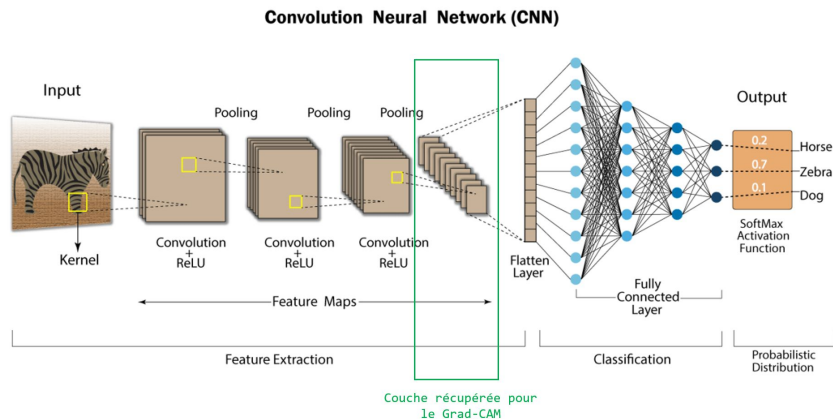
03 Modèles utilisés

YOLO avec heatmaps

Création des heatmaps

Fonctionnement de Grad-CAM (Gradient-weighted Class Activation Mapping) :

- 1 - Sélection de la dernière couche de convolution (avant les couches entièrement connectées)
- 2 - Calcul des gradients de la classe d'intérêt et pondération de ces derniers
- 3 - Génération des cartes de chaleur à partir des cartes pondérées
- 4 - Superposition sur l'image d'origine : formation des cartes de chaleur





Modèle depuis lequel on récupère les couches : EfficientNet



03 Modèles utilisés

YOLO avec heatmaps



Présentation des heatmaps



Heatmap facilement exploitable



Heatmap moyennement exploitable



Heatmap difficilement exploitable

03 Modèles utilisés

YOLO avec heatmaps

Utilisation de la librairie cv2 (threshold et findContours)

1 - Création d'un masque binaire pour récupérer les zones intéressantes (choix du threshold)

2 - Récupération des bords des zones créées, et création des boîtes avec ces valeurs

3 - Limitation du "bruit" avec des contraintes de taille et de proportions

Récupération des boîtes englobantes






Image avec "bruit"




Threshold trop grand



Threshold trop petit


03 Modèles utilisés

YOLO avec heatmaps



Premier test : on ne garde que la plus grande boîte englobante

Résultats




Second test : on garde plus de boîtes englobantes

04

Conclusion

Modèle	Accuracy sur le test set
DenseNet121	75%
DenseNet201	76%
ResNet50	75.4%
ResNet101	74.9%
ResNet152	75.4%
YOLO	74.1%
YOLO avec heatmaps	40,8%
EfficientNetB1	81.7%





04

Conclusion

Amélioration possible

- Augmentation des données (GANs, etc.)
- Enrichissement du dataset
- Optimisation des modèles:
 - Nas
 - Ensemble learning
- Collaboration interdisciplinaire

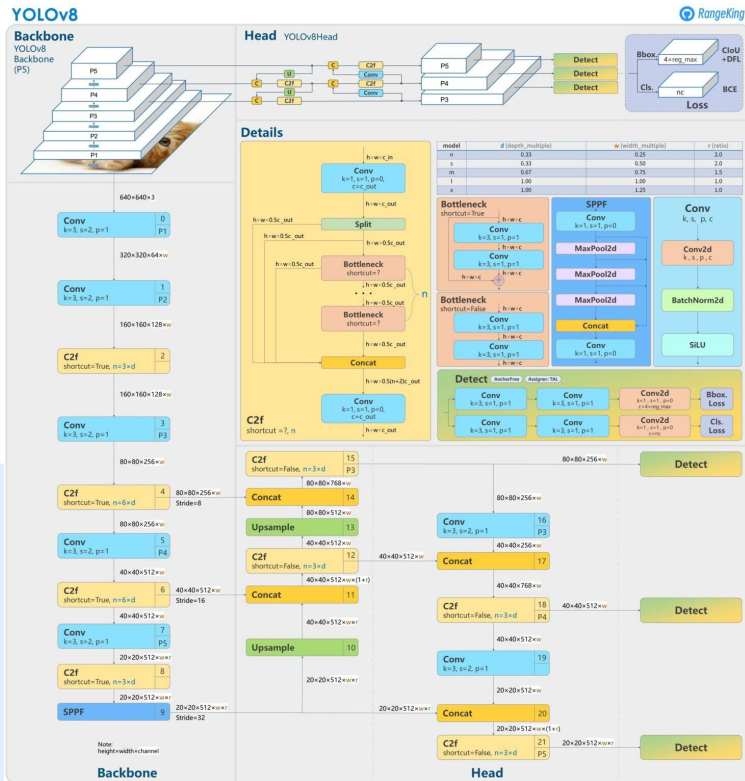




Questions ?

Modèles utilisés

Fonctionnement



- Couches de convolution et d'activation
- Blocs résiduels (amélioration de la propagation des gradients)
- Feature Pyramid Network (gestion de la détection multi-échelle)
- Têtes de détection (prédiction des boîtes, des scores et des classes)